

Breach system

المقدمة

بسم الله الرحمن الرحيم, في المقالة هذي بتكلم كيف ممكن تسوي موقع password lookup
اول شي بستعمل golang ك باك اند و mongodb ك قاعدة بيانات بحكم سرعتهم الاثنين لأنني بركز
على السرعة في هذا البرنامج

تصميم الموقع

هذي رسمة بسيطة للموقع قبل التحسين فيها كيف الموقع يشتغل




Figure1 system design

Database

بشكل عام قاعدة البيانات عندنا بيكون فيها table وحدة مخزن فيها كل الايميلات و passwords و هذا تصميم حلو بس بيسبب مشكلة لنا لو بنحط مليارات البيانات لأنه كل ما يبي يسوي query بيمشي على كل ال rows لين يحصل اللي يبي و هذا يأخذ وقت طويل مرة




Figure2 before optimizing

طيب وش الحل؟ افضل شي انك تقسم البيانات على اكثر من table بحيث توزعها مثلا بدال ما يبحث في 100 صندوق يصير يبحث بس في 10 صناديق و يترك ال 90 هذا بيوفر علي وقت مرة رهيب.

طيب كيف سويتها؟ على حسب الخانات و الايميل هنا جدول فيه الايميل و في أي table بيتخزن بناء على الايميل نفسة

Email	Table name
asd@gmail.com	3_gmail
hello@yahoo.com	5_yahoo

aziz@gmail.com	4_gmail
Rsxx123@gmail.com	7_gmail

و كذا لما قاعدة البيانات تبي تبحث عن أي ايميل و الباسورد حقة يصير اسهل لها بكثير هذي الحركة فرقت معي بشكل مرعب ممكن ال query تأخذ 30 ثانية الحين ما تأخذ ms4 و اغلب الوقت حقها في ال network

Collection name	Properties	Storage size	Data size	Documents	Avg. document size
email_1	-	20.48 kB	2.09 kB	36	58.00 B
email_2	-	36.86 kB	76.46 kB	1.3K	59.00 B
email_3	-	663.55 kB	2.80 MB	47K	60.00 B
email_4	-	23.67 MB	102.46 MB	1.7M	61.00 B
email_5	-	866.50 MB	3.75 GB	60M	62.00 B
email_6	-	2.01 GB	8.74 GB	139M	63.00 B
email_7	-	4.14 MB	17.92 MB	280K	64.00 B
email_8	-	4.28 GB	18.07 GB	278M	65.00 B
email_9	-	5.74 GB	24.58 GB	372M	66.00 B

Figure3 table view

Indexes

أيضا عشان يكون الموضوع اسرع استخدمت indexes و فكرتها مثل الكتاب لما تبي تبحث عن شي تروح للفهرس قواعد البيانات نفس الشي ترتب البيانات عشان لما تبحث داخل ال table يكون مرة سريع دمجت ال indexes مع تكنيك اني سويت اكثر من table و حصلت على أداء خرافي كأني موب جالس تعامل مع مليارات البيانات

Reduce database size

طبيب بالنسبة للفكرة حققت اني قسمت ال tables لها فائدة ثانية غير السرعة و هي توفير مساحة لما كنت اخزن البيانات اول كانت كذا

```
{email:"hello@gmail.com",password:"anything"}
```

اما الحين لأنني بخزنها في 5_gmail اقدر اني احذف @gmail.com ف صرت اخزنها كذا

```
{email:"hello",password:"anything"}
```

و عشان اوفر اكثر غيرت email و password الى p و e ف طلعت معي كذا

```
{e:"hello",p:"anything"}
```

بالطريقة هذي قدرت اوفر اكثر من 60% من المساحة و بنفس الوقت زدت سرعة ال parsing لأن صارت البيانات اقل كاني ضغطتها و لأنني مسمي ال gmail table ف اعرف ان الايميل هذا حق gmail

ف صار تصميم قاعدة البيانات حقي مثل كذا




Figure4 database design

MONGODB CREDENTIAL LOOKUP

Email Password Lookup

abasd2@gmail.com

Search

Match found from database in 5 ms.

EMAIL	PASSWORD	
abasd2	password3	Copy

spazq5

baz2m0lq3

cobλ

بعد كل هذي التحسينات كان الرد من السيرفر يأخذ فقط 5 ms و يزيد و يقل بشكل طفيف مع العلم ان كمية ال breach عندي 5 مليار ايميل و باسوورد و حتى لو زادت على 10 او 30 مليار بتكون السرعة مثل ماهي نتيجة تصميم قواعد البيانات اللي يخليها بدال ما تقرا كل شي بس تقرا شي محدد فقط

Cache

و اخر شي اضيفت cache لو الايميل هذا انبحث عنه يتخزن نتيجة بالرام عشان ترجع بسرعة للمستخدم بدون ما يكلم قاعدة البيانات منها يخفف الضغط و منها يكون اسرع

MONGODB CREDENTIAL LOOKUP

Email Password Lookup

abasd2@gmail.com

Search

Match found from cache in 3 ms.

EMAIL	PASSWORD	
abasd2	password3	Copy

abasd2

password3

Copy

هل فيه مجال زيادة للتحسين؟

اكيد فيه طرق احسن فيها المشروع و منها اني اقسم الtables اكثر ف اقدر اقسماها على اول حرف أيضا بيصير عندي tables اكثر بس علطول من الكود بيعرف لأي table بيروح لكن ما اضيفتها لأن الرد من السيرفر مرة سريع 5ms فقط لكن لو وصلت الايميلات الى درجة ان الموضوع صار بطيء ممكن اضيفها أيضا ممكن تقسم الload على اكثر من سيرفر بحيث يكون كل سيرفر ماسك جزء من البيانات ف تصير تنقسم على مستوى servers بدال tables

